

Proposed Method: Conflict-Aware Evidence Arbitration with Factoid-Level Resolution

Tổng quan

Pipeline được thiết kế theo paradigm "arbitrate-then-verify-then-generate" — mở rộng từ ArbGraph bằng cách bổ sung factoid-level conflict localization và iterative retrieval loop. Thay vì chỉ suppress/validate claims ở mức câu, hệ thống phân tích chi tiết slot nào trong claim mâu thuẫn, từ đó hướng dẫn retrieval có mục tiêu hơn.

Luồng xử lý:

Documents → Claim Extraction → Claim Canonical → Evidence Graph → Retrieve → Conflict Zone → Iterative Loop → Generation

Phase 1 — Claim Extraction

Mô tả

Với mỗi document đầu vào, hệ thống dùng LLM để viết lại nội dung thành các atomic statements dạng declarative — gọi là claims. Mỗi claim giữ nguyên semantic của document gốc nhưng được clean về mặt ngôn ngữ.

Sau đó, BGE-M3 encode claim thành dense vector để phục vụ similarity search ở các bước sau.

Ví dụ

Document gốc:

"Chiến dịch Điện Biên Phủ, diễn ra từ tháng 3 đến tháng 5 năm 1954, đã kết thúc với chiến thắng quyết định của Quân đội Nhân dân Việt Nam dưới sự chỉ huy của Đại tướng Võ Nguyên Giáp."

Claim được extract:

- **c1:** "Chiến dịch Điện Biên Phủ diễn ra năm 1954."
- **c2:** "Quân đội Nhân dân Việt Nam giành chiến thắng tại Điện Biên Phủ."
- **c3:** "Võ Nguyên Giáp chỉ huy chiến dịch Điện Biên Phủ."

Phase 2 — Claim Canonical

Mô tả

Nhiều documents khác nhau có thể sinh ra claims diễn đạt cùng một sự kiện theo cách khác nhau. Nếu giữ tất cả, evidence graph sẽ có quá nhiều nodes dư thừa và quá nhiều edges LLM phải xử lý.

Claim canonical gom nhóm các claims tương đồng về một representative claim thông qua hai bước:

1. **Bước 1:** Tính cosine similarity giữa các claim embeddings. Nếu $\text{sim}(c_i, c_j) > \theta$ thì chúng được xét là candidates để merge.
2. **Bước 2:** Áp dụng điều kiện tách cho claims chứa năm hoặc số — dù similarity cao, nếu hai claims có temporal/numerical value khác nhau thì không merge vì đây chính là nguồn gốc của conflict.

Ví dụ

- **c1:** "Điện Biên Phủ diễn ra năm 1954." [$\text{sim}=0.94$]
- **c2:** "Trận Điện Biên Phủ xảy ra vào 1954." → MERGE vào **c1**
- **c3:** "Điện Biên Phủ diễn ra năm 1953." [$\text{sim}=0.91$]
→ KHÔNG merge dù sim cao vì năm khác nhau. Giữ nguyên là node riêng biệt.

Output: Tập claim representatives $\{r_1, r_2, r_3, \dots\}$ — mỗi representative đại diện cho một nhóm claims tương đồng.

Phase 3 — Evidence Graph Construction

Mô tả

Xây dựng đồ thị $G = (V, E)$ trong đó:

- **Node** = claim representative
- **Edge** = quan hệ giữa hai claims: {support, contradict, neutral}
- **Edge score** = độ tin cậy của nhãn edge, tính bằng NLI confidence score

Quy trình tạo edge:

1. **Bước 1:** LLM phán xét quan hệ giữa cặp (r_i, r_j) : "support", "contradict", hoặc "neutral".
2. **Bước 2:** NLI quality check xác nhận nhãn từ LLM. Nếu NLI score dưới ngưỡng τ_{nli} thì edge bị loại bỏ.
3. **Bước 3:** Edge score = NLI confidence của nhãn được chọn.

Ví dụ

- **r1:** "Điện Biên Phủ diễn ra năm 1954."
- **r3:** "Điện Biên Phủ diễn ra năm 1953."
 - *LLM label:* contradict
 - *NLI check:* $P(\text{contradict} | r_1, r_3) = 0.89 > \tau_{\text{nli}}$

- $\rightarrow \text{Edge } (r1, r3): \text{contradict, score}=0.89$
- **r1:** "Điện Biên Phủ diễn ra năm 1954."
- **r2:** "Võ Nguyên Giáp chỉ huy chiến dịch Điện Biên Phủ."
 - *LLM label:* neutral
 - *NLI check:* $P(\text{neutral}) = 0.91$
 - $\rightarrow \text{Edge } (r1, r2): \text{neutral, score}=0.91$

Phase 4 — Query-Aware Retrieval

Mô tả

Khi nhận query, hệ thống tính `claim_relevance_score` giữa query và từng claim representative bằng hybrid retrieval:

$$\text{claim_relevance_score}(q, r_i) = \alpha * \text{dense_score}(q, r_i) + (1-\alpha) * \text{sparse_score}(q, r_i)$$

Sau đó áp dụng Reciprocal Rank Fusion (RRF) để combine rankings.

Điểm đặc biệt: khi chọn top-k claims, hệ thống đảm bảo tỷ lệ xuất hiện của edge types (contradict/support/neutral) được cân bằng — tránh việc chỉ retrieve các claims tương đồng nhau mà bỏ sót conflict.

Ví dụ

Query: "Chiến dịch Điện Biên Phủ kết thúc năm nào?"

Retrieval results (top-5):

- **r1:** "Điện Biên Phủ diễn ra năm 1954." (score=0.91)
- **r3:** "Điện Biên Phủ diễn ra năm 1953." (score=0.87)
- **r2:** "Võ Nguyên Giáp chỉ huy chiến dịch." (score=0.74)
- **r4:** "Pháp thất bại tại Điện Biên Phủ." (score=0.71)
- **r5:** "Chiến dịch kéo dài 56 ngày đêm." (score=0.68)

Edge frequency trong top-5:

- **contradict:** (r1,r3) $\rightarrow$ 1 pair
- **support:** (r1,r4), (r3,r4) $\rightarrow$ 2 pairs
- **neutral:** (r1,r2), (r2,r3),... $\rightarrow$ nhiều pairs
- $\rightarrow$ *Balance check:* OK, có đủ conflict pairs

Phase 5 — Conflict Zone

Mô tả

Đây là phase cốt lõi, gồm hai nhiệm vụ song song:

5.1 — Tính Claim Credibility Score

Dùng cơ chế arbitration của ArbGraph — propagate credibility signals qua evidence graph:

$$\text{claim_credibility_score}(r_i) = \sum \text{edge_score}(r_j \rightarrow r_i) [\text{với edge type} = \text{support}] - \sum \text{edge_score}(r_k \rightarrow r_i) [\text{với edge type} = \text{contradict}]$$

Iterative update cho đến khi scores hội tụ. Claims có nhiều support từ claims credible khác sẽ có score cao; claims bị nhiều claims contradict sẽ bị suppress.

Ví dụ:

- **r1**: "1954" được support bởi r4 (score=0.89), r5 (score=0.82) và bị contradict bởi r3 (score=0.89)
 - $\rightarrow \text{credibility_score}(r1) = 0.89 + 0.82 - 0.89 = 0.82$
- **r3**: "1953" bị contradict bởi r1 (score=0.89), r4 (score=0.76) và không có support
 - $\rightarrow \text{credibility_score}(r3) = 0 - 0.89 - 0.76 = -1.65$
 - $\rightarrow$ r3 bị suppress

5.2 — Factoid Decomposition và Conflict Localization

Với mỗi conflict pair (ri, rj) tìm được trong top-k:

Bước 1 — Factoid Decomposition:

Dùng LLM (hoặc NER + RE model) để extract typed slots từ mỗi claim theo schema cố định:

Schema = {temporal, numerical, entity_subject, entity_object, relation, location}

Plaintext

r1: "Điện Biên Phủ diễn ra năm 1954"

```
Si = {  
  temporal: "1954",  
  entity_subject: "Chiến dịch Điện Biên Phủ",  
  relation: "diễn ra",  
  location: null,  
  numerical: null,  
  entity_object: null  
}
```

r3: "Điện Biên Phủ diễn ra năm 1953"

```
Sj = {  
  temporal: "1953",  
  entity_subject: "Chiến dịch Điện Biên Phủ",  
  relation: "diễn ra",  
  location: null,  
  numerical: null,  
  entity_object: null  
}
```

```
entity_object: null
}
```

Bước 2 — Factoid Alignment:

So sánh cùng slot type giữa hai claims:

Aligned pairs:

- (temporal_i, temporal_j) = ("1954", "1953")
- (entity_subject_i, entity_subject_j) = (same, same)
- (relation_i, relation_j) = (same, same)

Bước 3 — Gán nhãn bằng rule-based + NLI:

- temporal: "1954" ≠ "1953" → string compare → contradict → 1
- entity_subject: match → entail → 0
- relation: match → entail → 0
- numerical: null vs null → skip
- location: null vs null → skip
- entity_object: null vs null → skip

Binary vectors:

- $p_i = [1, 0, 0]$ (temporal conflict)
- $p_j = [1, 0, 0]$

Bước 4 — Tính Conflict Intensity:

$XOR(p_i, p_j) = [0, 0, 0]$

→ Không dùng XOR trực tiếp mà dùng:

- conflict_slots = {slot: $val_i \neq val_j$ } = {temporal}
- conflict_intensity_score = $1/3 \approx 0.33$

Bước 5 — Conflict Localization:

Lưu thông tin conflict để đưa vào iterative loop:

JSON

```
conflict_info = {
  "pair": ["r1", "r3"],
  "slot": "temporal",
  "values": ["1954", "1953"],
  "intensity": 0.33,
  "credibility": [0.82, -1.65]
```

}

Phase 6 — Iterative Retrieval Loop

Mô tả

Loop được trigger khi tồn tại conflict pairs chưa được resolve. Mỗi iteration:

1. **Bước 1 — Formulate conflict-aware query:** Inject conflict_info vào query gốc.
 - *Query gốc:* "Chiến dịch Điện Biên Phủ kết thúc năm nào?"
 - *Conflict-aware query:* "Verify: Chiến dịch Điện Biên Phủ — Source A cho rằng năm 1954, Source B cho rằng năm 1953. [temporal conflict]"
2. **Bước 2 — Retrieve new documents:** Dùng conflict-aware query để retrieve documents mới từ corpus hoặc live search.
3. **Bước 3 — Update evidence graph:** Extract claims từ documents mới, thêm vào graph, re-run arbitration, update credibility scores.
4. **Bước 4 — Re-compute conflict intensity:** Nếu intensity giảm dưới threshold → break loop.

Stopping conditions

- **Condition A:** $\text{conflict_intensity_score} < \theta_intensity$ → conflict resolved → break
- **Condition B:** $\text{iterations} \geq \text{max_iter}$ → conflict unresolvable → break, flag as "genuine disagreement"
- **Condition C:** new documents không cung cấp thêm evidence mới → break

Ví dụ một iteration

- **Iteration 1:**
 - Conflict-aware query retrieve được: **r6:** "Chiến dịch Điện Biên Phủ kết thúc ngày 7/5/1954." (source: Bộ Quốc phòng VN)
 - Update graph:
 - (r6, r1): support, score=0.94
 - (r6, r3): contradict, score=0.91
 - Update credibility:
 - $\text{credibility_score}(r1) += 0.94 \rightarrow 1.76$
 - $\text{credibility_score}(r3) -= 0.91 \rightarrow -2.56$
 - Re-compute intensity(r1, r3): temporal slot vẫn conflict, intensity = 0.33
 - Nhưng credibility gap đủ lớn: **r1 credibility = 1.76 >> r3 credibility = -2.56** → Loop break, r3 suppressed, r1 validated.

Phase 7 — Generation

Input cho LLM

- *Validated claims (theo credibility score):*

- **r1:** "1954" [credibility=1.76, intensity=0.33]
 - **r2:** "Võ Nguyên Giáp chỉ huy" [credibility=1.20]
 - **r4:** "Pháp thất bại" [credibility=0.95]
 - **r5:** "56 ngày đêm" [credibility=0.88]
- **Conflict summary (nếu unresolved):**
 - "Hai nguồn mâu thuẫn về [temporal]: 1954 (credibility=1.76) vs 1953 (credibility=-2.56). Không thể resolve sau N iterations."

Bảng tóm tắt các components

Phase	Input	Output
1. Claim Extraction	Documents	Claims + embeddings
2. Claim Canonical	Claims	Representative claims
3. Evidence Graph	Representatives	$G = (V, E)$ với edge scores
4. Retrieval	Query + Graph	Top-k claims (balanced)
5. Conflict Zone	Top-k claims with contradiction edge	credibility_score conflict_intensity_score conflict_localization
6. Iterative Loop	Conflict info	Updated graph + scores
7. Generation	Validated claims	Long-form answer